

非 27B 模型 vLLM 加载指令

适用于当前 /DATA/models 目录与 test 环境

使用规则：一次只加载一个模型；以下命令均使用 8000 端口。

先执行：conda activate test

当前文档不包含 Qwen3.8-27B；27B 继续使用单独的 4bit 加载方案。

命令以前台方式运行。需要结束当前模型时，在该终端按 Ctrl+C。

一、建议优先用于业务测试的模型

1. MiniCPM5-1B

```
vllm serve /DATA/models/MiniCPM5-1B \  
  --served-model-name MiniCPM5-1B \  
  --host 0.0.0.0 \  
  --port 8000 \  
  --dtype bfloat16 \  
  --gpu-memory-utilization 0.75 \  
  --max-model-len 16384 \  
  --trust-remote-code
```

2. Qwen3-0.6B

```
vllm serve /DATA/models/Qwen3-0.6B \  
  --served-model-name Qwen3-0.6B \  
  --host 0.0.0.0 \  
  --port 8000 \  
  --dtype bfloat16 \  
  --gpu-memory-utilization 0.75 \  
  --max-model-len 16384
```

3. Qwen3.5-0.8B

```
vllm serve /DATA/models/Qwen3.5-0.8B \  
  --served-model-name Qwen3.5-0.8B \  
  --host 0.0.0.0 \  
  --port 8000 \  
  --dtype bfloat16 \  
  --gpu-memory-utilization 0.75 \  
  --max-model-len 16384 \  
  --language-model-only
```

4. Qwen3-1.7B

```
vllm serve /DATA/models/Qwen3-1.7B \  
  --served-model-name Qwen3-1.7B \  
  --host 0.0.0.0 \  
  --port 8000 \  
  --dtype bfloat16 \  
  --gpu-memory-utilization 0.80 \  
  --language-model-only
```

```
--max-model-len 16384
```

5. Qwen3.5-2B

```
vllm serve /DATA/models/Qwen3.5-2B \  
--served-model-name Qwen3.5-2B \  
--host 0.0.0.0 \  
--port 8000 \  
--dtype bfloat16 \  
--gpu-memory-utilization 0.80 \  
--max-model-len 16384 \  
--language-model-only
```

6. VibeThinker-3B

```
vllm serve /DATA/models/VibeThinker-3B \  
--served-model-name VibeThinker-3B \  
--host 0.0.0.0 \  
--port 8000 \  
--dtype bfloat16 \  
--gpu-memory-utilization 0.82 \  
--max-model-len 16384
```

7. Phi-4-mini-instruct

```
vllm serve /DATA/models/Phi-4-mini-instruct \  
--served-model-name Phi-4-mini-instruct \  
--host 0.0.0.0 \  
--port 8000 \  
--dtype bfloat16 \  
--gpu-memory-utilization 0.82 \  
--max-model-len 16384 \  
--trust-remote-code
```

8. Qwen3-4B

```
vllm serve /DATA/models/Qwen3-4B \  
--served-model-name Qwen3-4B \  
--host 0.0.0.0 \  
--port 8000 \  
--dtype bfloat16 \  
--gpu-memory-utilization 0.85 \  
--max-model-len 16384
```

9. Qwen3.5-4B

```
vllm serve /DATA/models/Qwen3.5-4B \  
--served-model-name Qwen3.5-4B \  
--host 0.0.0.0 \  
--port 8000 \  
--dtype bfloat16 \  
--gpu-memory-utilization 0.85 \  
--max-model-len 16384 \  
--language-model-only
```

10. Qwen2.5-7B-Instruct

```
vllm serve /DATA/models/Qwen2.5-7B-Instruct \  
  --served-model-name Qwen2.5-7B-Instruct \  
  --host 0.0.0.0 \  
  --port 8000 \  
  --dtype bfloat16 \  
  --gpu-memory-utilization 0.88 \  
  --max-model-len 8192
```

11. DeepSeek-R1-Distill-Qwen-7B

```
vllm serve /DATA/models/DeepSeek-R1-Distill-Qwen-7B \  
  --served-model-name DeepSeek-R1-Distill-Qwen-7B \  
  --host 0.0.0.0 \  
  --port 8000 \  
  --dtype bfloat16 \  
  --gpu-memory-utilization 0.88 \  
  --max-model-len 8192
```

12. Hunyuan-7B-Instruct

```
vllm serve /DATA/models/Hunyuan-7B-Instruct \  
  --served-model-name Hunyuan-7B-Instruct \  
  --host 0.0.0.0 \  
  --port 8000 \  
  --dtype bfloat16 \  
  --gpu-memory-utilization 0.88 \  
  --max-model-len 8192 \  
  --trust-remote-code
```

13. MiMo-7B-RL

```
vllm serve /DATA/models/MiMo-7B-RL \  
  --served-model-name MiMo-7B-RL \  
  --host 0.0.0.0 \  
  --port 8000 \  
  --dtype bfloat16 \  
  --gpu-memory-utilization 0.88 \  
  --max-model-len 8192 \  
  --trust-remote-code
```

14. Qwen3-8B

```
vllm serve /DATA/models/Qwen3-8B \  
  --served-model-name Qwen3-8B \  
  --host 0.0.0.0 \  
  --port 8000 \  
  --dtype bfloat16 \  
  --gpu-memory-utilization 0.88 \  
  --max-model-len 8192
```

15. MiniCPM4.1-8B

```
vllm serve /DATA/models/MiniCPM4.1-8B \
--served-model-name MiniCPM4.1-8B \
--host 0.0.0.0 \
--port 8000 \
--dtype bfloat16 \
--gpu-memory-utilization 0.88 \
--max-model-len 8192 \
--trust-remote-code
```

16. InternLM3-8B-Instruct

```
vllm serve /DATA/models/InternLM3-8B-Instruct \
--served-model-name InternLM3-8B-Instruct \
--host 0.0.0.0 \
--port 8000 \
--dtype bfloat16 \
--gpu-memory-utilization 0.88 \
--max-model-len 8192 \
--trust-remote-code
```

二、Base 模型（可加载，但不建议直接作为业务对话模型）

Base 模型主要用于继续训练、SFT/LoRA 或基座能力对照。若只是做违章理解、根因分析、整改建议、作业复盘等业务测试，优先使用上面的后训练/指令模型。

1. Qwen3-0.6B-Base

```
vllm serve /DATA/models/Qwen3-0.6B-Base \
--served-model-name Qwen3-0.6B-Base \
--host 0.0.0.0 --port 8000 \
--dtype bfloat16 --gpu-memory-utilization 0.75 \
--max-model-len 16384
```

2. Qwen3-1.7B-Base

```
vllm serve /DATA/models/Qwen3-1.7B-Base \
--served-model-name Qwen3-1.7B-Base \
--host 0.0.0.0 --port 8000 \
--dtype bfloat16 --gpu-memory-utilization 0.80 \
--max-model-len 16384
```

3. Qwen3.5-0.8B-Base

```
vllm serve /DATA/models/Qwen3.5-0.8B-Base \
--served-model-name Qwen3.5-0.8B-Base \
--host 0.0.0.0 --port 8000 \
--dtype bfloat16 --gpu-memory-utilization 0.75 \
--max-model-len 16384 --language-model-only
```

4. Qwen3.5-2B-Base

```
vllm serve /DATA/models/Qwen3.5-2B-Base \  
  --served-model-name Qwen3.5-2B-Base \  
  --host 0.0.0.0 --port 8000 \  
  --dtype bfloat16 --gpu-memory-utilization 0.80 \  
  --max-model-len 16384 --language-model-only
```

5. Qwen3.5-4B-Base

```
vllm serve /DATA/models/Qwen3.5-4B-Base \  
  --served-model-name Qwen3.5-4B-Base \  
  --host 0.0.0.0 --port 8000 \  
  --dtype bfloat16 --gpu-memory-utilization 0.85 \  
  --max-model-len 16384 --language-model-only
```

6. Qwen3-8B-Base

```
vllm serve /DATA/models/Qwen3-8B-Base \  
  --served-model-name Qwen3-8B-Base \  
  --host 0.0.0.0 --port 8000 \  
  --dtype bfloat16 --gpu-memory-utilization 0.88 \  
  --max-model-len 8192
```

三、加载后只检查是否成功

不需要对话测试时，只看 GPU 和启动日志即可：

```
nvidia-smi
```

```
curl http://127.0.0.1:8000/v1/models
```

若只是确认 vLLM 服务已经完成启动，可在启动终端中看到类似 “Application startup complete” 的信息。